

CHALLENGE BRIEF

IA asistencial para análisis de radiografías de columna

Organización: Agnodis

Sector: Salud / tecnología médica

Persona referente: Kenneth Taipe – IA Architect

Hackathon de Innovación Aplicada

1. Contexto del problema

Actualmente, el análisis de radiografías de columna es realizado por un profesional médico, principalmente un médico radiólogo, quien revisa las imágenes para determinar la presencia de alteraciones estructurales y otros hallazgos relevantes. Dependiendo del caso, puede requerirse además la valoración de un médico especialista para relacionar los hallazgos radiológicos con la condición clínica del paciente.

Este proceso implica una revisión visual detallada de las imágenes, la identificación de alteraciones, la comparación entre estructuras y, en determinados casos, la realización de mediciones específicas, por ejemplo para valorar la curvatura de la columna.

Agnodis identifica como principal dificultad que este análisis depende del tiempo disponible del profesional y de la experiencia del evaluador, especialmente cuando existe un volumen importante de estudios. Además, algunos hallazgos pueden ser sutiles y requieren una revisión cuidadosa.

El reto busca desarrollar una herramienta de apoyo diagnóstico basada en inteligencia artificial que realice una primera preevaluación de la imagen, identifique posibles hallazgos y los señale al médico para facilitar y agilizar su revisión.

La inteligencia artificial no reemplazará el diagnóstico médico. Funcionará como un segundo apoyo para el profesional, ayudándole a enfocar su atención y a reducir la posibilidad de pasar por alto determinados hallazgos.

2. El reto

Desarrollar una prueba de concepto basada en inteligencia artificial capaz de analizar radiografías de columna y reconocer determinados patrones radiográficos de manera consistente.

Para el hackathon, Agnodis propone priorizar los siguientes hallazgos:

- escoliosis / rotoescoliosis;
- hipercifosis;
- hiperlordosis;
- rectificación de la lordosis lumbar;
- vértebras de transición;
- espina bífida;
- alteraciones evidentes de los espacios intervertebrales.

El objetivo principal será demostrar la capacidad de detección y clasificación de hallazgos.

El sistema deberá ser capaz de recibir una radiografía de columna, identificar si existe o no un determinado hallazgo, clasificar el tipo de alteración y generar una salida sencilla que pueda ser interpretada como una preevaluación para el profesional médico.

Cuando sea posible, también podrá señalar visualmente la zona de la imagen donde identificó el hallazgo.

No es indispensable desarrollar durante el hackathon una segmentación anatómica completa ni un sistema clínico terminado. El foco estará en demostrar que el modelo puede reconocer patrones radiográficos relevantes y apoyar la revisión médica.

3. Pregunta central

¿Cómo podríamos desarrollar una herramienta basada en inteligencia artificial capaz de analizar radiografías de columna, detectar y clasificar hallazgos relevantes y generar una preevaluación técnicamente verificable que apoye la revisión del profesional médico?

4. ¿Quiénes podrían beneficiarse?

La solución podría beneficiar principalmente a:

- médicos radiólogos responsables de analizar radiografías de columna;
- médicos especialistas que requieren relacionar los hallazgos radiológicos con la condición clínica del paciente;
- profesionales que deben revisar un volumen importante de estudios;
- pacientes, mediante un proceso de revisión apoyado por una herramienta capaz de identificar posibles hallazgos.

La herramienta deberá funcionar siempre como apoyo a la revisión profesional y no como sustituto del diagnóstico médico.

5. ¿Qué debería demostrar el prototipo?

La prueba de concepto debería demostrar que puede:

- recibir una radiografía de columna;
- identificar la presencia o ausencia de determinados hallazgos;
- clasificar el tipo de alteración identificada;
- cuando sea posible, señalar visualmente la zona de la imagen asociada al hallazgo;
- generar una salida sencilla que pueda utilizarse como preevaluación;
- comparar sus predicciones con una etiqueta médica de referencia;
- demostrar su desempeño con imágenes que el modelo no haya utilizado durante el entrenamiento;
- mantener un rendimiento consistente cuando se incorporen nuevos casos.

El objetivo no es demostrar que el modelo funciona únicamente con las imágenes utilizadas para construirlo, sino comprobar que puede reconocer patrones también en casos nuevos.

6. Alcance del reto

Dentro del reto pueden desarrollarse componentes como:

- preparación y procesamiento de radiografías de columna;
- inteligencia artificial aplicada al análisis de imágenes;
- CNN (“red neuronal convolucional”);
- detección de hallazgos radiográficos;
- clasificación de alteraciones;
- señalamiento visual de zonas relevantes de la imagen;
- generación de una salida de preevaluación;
- comparación de predicciones con etiquetas médicas de referencia;
- evaluación del desempeño del modelo;
- validación mediante imágenes no utilizadas durante el entrenamiento.

El equipo deberá concentrarse en demostrar que el modelo puede reconocer determinados patrones radiográficos de manera consistente.

No será necesario abordar simultáneamente todas las patologías priorizadas ni desarrollar una segmentación anatómica perfecta. El valor del prototipo estará en demostrar de manera rigurosa la detección y clasificación de los hallazgos seleccionados.

7. Fuera de alcance y restricciones

No se espera durante el hackathon:

- desarrollar un sistema clínico completo;
- sustituir el diagnóstico o criterio de un profesional médico;
- resolver todas las patologías posibles de columna;
- desarrollar obligatoriamente una segmentación anatómica completa;
- presentar los resultados del modelo como un diagnóstico médico definitivo.

La solución deberá mantenerse como una herramienta de apoyo diagnóstico y como una prueba de concepto técnicamente evaluable.

8. Información e insumos

Agnodis entregará un dataset anonimizado de radiografías de columna para el desarrollo del reto. Las imágenes permitirán trabajar en la identificación de las patologías y hallazgos establecidos para el desafío.

Cada imagen deberá contar con una referencia que permita comprobar si la clasificación realizada por el modelo es correcta. Esta referencia corresponderá a una ground truth.

La predicción realizada por la CNN deberá compararse imagen por imagen con esta etiqueta de referencia.

Los datos destinados a evaluar el desempeño del modelo deberán mantenerse separados de los utilizados durante el entrenamiento, de manera que la evaluación final se realice con imágenes que el modelo no haya visto previamente.

9. ¿Cómo sabremos si la propuesta tiene potencial?

Agnodis ha establecido un criterio técnico específico para evaluar el desempeño del prototipo.

La prueba deberá realizarse sobre un set de test que la CNN no haya utilizado durante su entrenamiento.

El equipo deberá presentar:

- una matriz de confusión (tabla que permite observar los aciertos y errores de clasificación);
- verdaderos positivos, falsos positivos, verdaderos negativos y falsos negativos por clase;
- F1-score (medida que combina precisión y recall) por clase;
- F1-score macro (promedio del F1-score de todas las clases, otorgando el mismo peso a cada una);
- especial atención al recall (capacidad del modelo para detectar correctamente los casos que realmente pertenecen a una clase patológica);

- una prueba con nuevas imágenes no utilizadas durante el entrenamiento para comprobar que el rendimiento se mantiene.

El criterio establecido por Agnodis será alcanzar un F1-score macro igual o superior a 0,89 sobre el conjunto de test independiente.

Este 0,89 no corresponde simplemente al accuracy (porcentaje total de clasificaciones correctas). En conjuntos de datos médicos pueden existir clases desbalanceadas: un modelo podría obtener un porcentaje elevado de aciertos clasificando la mayoría de las imágenes dentro de la clase más frecuente y, al mismo tiempo, fallar en la identificación de patologías.

Por esta razón, Agnodis establece el F1-score como criterio de evaluación, ya que permite considerar conjuntamente la precisión y el recall.

Cada predicción deberá compararse con la etiqueta médica de referencia. A partir de esa comparación se construirá la matriz de confusión y se calcularán las métricas de desempeño.

Los falsos negativos —casos que presentan una patología pero que el modelo no identifica como tales— deberán recibir especial atención debido a su relevancia dentro del objetivo del reto.

Además, el equipo deberá demostrar que, al incorporar un nuevo lote de imágenes que no formaron parte del entrenamiento, las métricas no se degradan de manera significativa. Esto permitirá comprobar que el modelo puede generalizar a nuevos casos y que no se limita a memorizar el conjunto utilizado para entrenarlo.

10. Habilidades que pueden aportar al equipo

Habilidades técnicas: programación, especialmente en Python; inteligencia artificial y aprendizaje automático; visión por computadora; procesamiento de imágenes; CNN (“redes neuronales convolucionales”); ciencia y análisis de datos; estadística; evaluación y validación de modelos; conocimientos o interés en imágenes médicas y ciencias de la salud.

Habilidades blandas: pensamiento crítico; capacidad de análisis; resolución de problemas; atención al detalle; interpretación de resultados; comunicación interdisciplinaria; trabajo colaborativo.

No es necesario que todas estas capacidades estén concentradas en una sola persona. La complementariedad entre perfiles será importante para abordar tanto el desarrollo del modelo como la evaluación rigurosa de sus resultados.



11. Referente de la organización

Kenneth Taipe

IA Architect – Agnodis

El referente podrá aportar contexto sobre el problema, los hallazgos priorizados, el dataset anonimizado y los criterios técnicos establecidos para evaluar el desempeño del prototipo.